



VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ

ZPO

ZPRACOVÁNÍ OBRAZU

Technická zpráva

Pokus o posouzení realističnosti a kvality rastrových
obrázků

Autor:
Petr Buchal

Login:
xbucha02

3. května 2019

1 Úvod

Jako zadání projektu jsem si vybral "Pokus o posouzení realističnosti a kvality rastrových obrázků". Mým cílem je zaměřit se na detekci manipulace s obrázky. To je v dnešní době kvůli umělé inteligenci schopné generovat zcela syntetické obrázky relevantnější než kdy dříve. Projekt jsem se rozhodl vypracovat sám.

2 Zadání

Cílem projektu je ověřit, zda snímek vznikl fotografováním nebo jiným procesem, zda případně snímek nebyl "retušován" a zda snímek má dobrou kvalitu, například že je dost ostrý a není v saturaci. Pro realizaci projektu je třeba použít například některý z níže uvedených algoritmů:

- Zjištění frekvenčního spektra různých "kousků" obrazu a ověření, zda může jít o fotografii (šum, apod.), lze ukázat na příkladu fotografie/nefotografie
- Zjištění, zda obrázek nemá lokálně odlišné charakteristiky (v některém místě rozmazán, někde ostrý, což by svědčilo o nízké kvalitě nebo o manipulaci)
- Ověření, zda v některých oblastech obrazu není saturace nebo "černo". pozor, saturace/černo nemusí být přímo hodnoty 255 nebo 0, ale mohou to být vysoké/nízké konstantní hodnoty

Na základě průzkumu metod, které se tímto tématem zabývají, jsem si vybral

2.1 Zpřesnění zadání

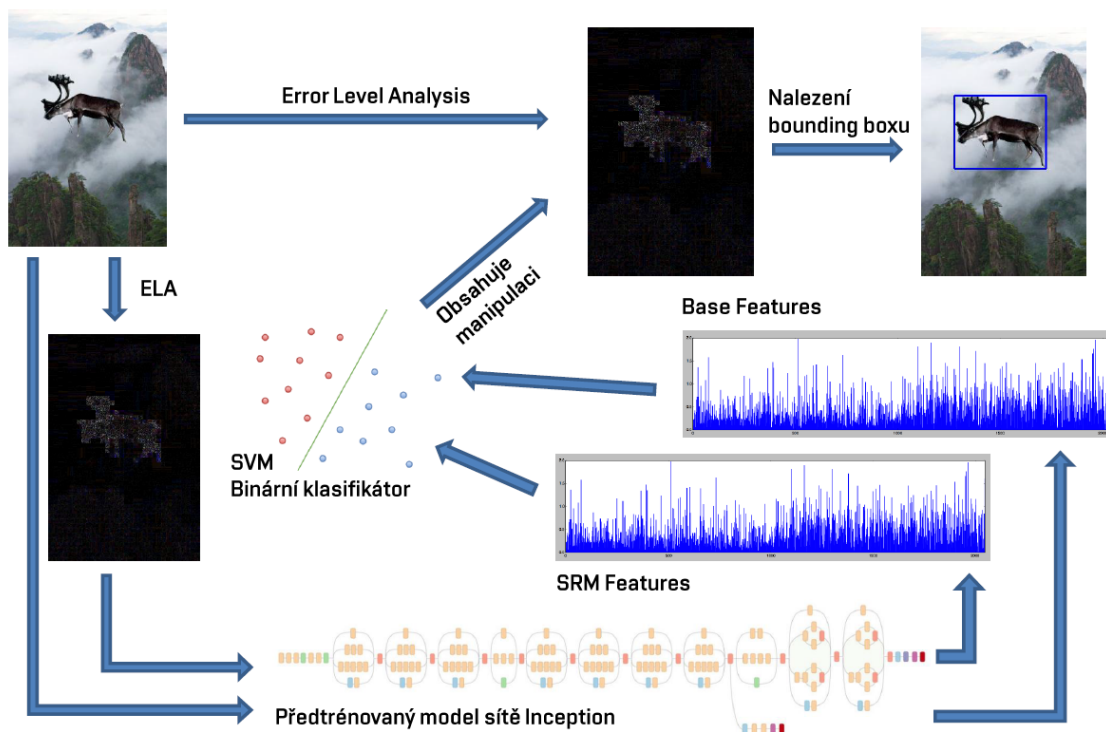
V projektu jsem se rozhodl rozpracovat část zadání, která se zabývá ověřováním, zdali byl zkoumaný obrázek retušován. Původně jsem chtěl implementovat metodu, která provádí analýzu obrázku neuronovou sítí z článku "Learning Rich Features for Image Manipulation Detection" [3]. Na konzultaci mi ale bylo doporučeno implementovat klasičtější metodu a tak jsem implementoval "Error Level Analysis" [1]. V projektu jsem ale nakonec uplatnil i prvky strojového učení, protože metoda ELA sama o sobě nedosahovala skvělých výsledků. Před její použitím v pipeline zpracování snímku jsem natrénovat binární klasifikátor SVM, který rozhoduje, zdali se na obrázku nějaká manipulace nachází [2]. ELA se poté použije pouze pokud klasifikátor řekne, že na obrázku se manipulace nachází.



Obrázek 1: Ukázky manipulací obrázků které se snaží projekt rozpoznat, převzato z [3].

3 Aplikace a implementace


Projekt jsem se rozhodl implementovat v jazyce Python. Aplikace je spustitelná z příkazového řádku. Pipeline implementované metody je vidět na obrázku 2.



Obrázek 2: Pipeline implementované detekce manipulace v obrazu.

3.1 Klasifikátor

Binární klasifikátor jsem se rozhodl implementovat, protože pokud chci dostat z metody ELA bounding box, musím na ni aplikovat určité operace, díky kterým metoda nachází bounding box i tam kde manipulace není a to jsem chtěl klasifikátorem ošetřit. Tedy hledání bounding boxu pomocí ELA se bude provádět pouze pokud klasifikátor určí, že se na obrázku nachází manipulace. Při vytváření klasifikátoru jsem vycházel hlavně z článku [2]. V článku se vytváří klasifikátor pomocí předtrénované neuronové sítě Inception a SVM. Konkrétně na vstup sítě Inception jde obrázek, na výstupu sítě vyleze vektor 2048 features, které se dále posílají na vstup SVM, která už klasifikuje zdali je na obrázku manipulace nebo nikoliv. Chtěl jsem vyzkoušet několik přístupů k tomu, co půjde na vstup SVM. V článku [3] se k detekci manipulací používá neuronová síť na jejíž vstup se kromě obrázku posílá ještě jeden obrázek zpracovaný SRM filtrem. Implementoval jsem SRM filter a zkusil jsem na vstup SVM posílat vektor 4096 features, které se skládaly z features samotného obrázku a features obrázku zpracovaného SRM filtrem. Dále jsem zkusil na vstup SVM posílat features ze samotného obrázku, obrázku a ELA a samotné ELA. Výsledky experimentů jsou vidět na obrázku 3. Nakonec jsem použil klasifikátor SVM, kterému jdou na vstup features z obrázku a z ELA.



Obrázek 3: Výsledky experimentů se vstupy jednotlivých klasifikátorů.

3.2 Error Level Analysis

Error Level Analysis je metoda, která se zabývá detekcí manipulovaných míst na základě ztrátové komprese [1] převážně JPGů. Metoda porovnává originální obrázek s komprimovaným obrázkem (např. 75 %) a místa, která byla manipulovaná vykazují odlišnou kompresi od zbytku obrázku. V obrázku zpracovaným metodou ELA poté hledám pomocí morfologických operací struktury, které byly pravděpodobně manipulované.

3.3 Datasetsy

Data se kterými jsem během projektu pracoval pocházela z datasetu CASIA1, který obsahuje 800 originálních snímků a cca 900 manipulovaných. Manipulované obrázky se poté skládají z vytvořených pomocí spojování různých obrázků (splicing) a kopírování a přesouvání částí stejného obrázku (copy-move), viz obrázek 1.

4 Závěr

Binární klasifikátor dosahuje úspěšnosti 90 % na testovací sadě, s čímž jsem spokojený. ELA metoda na nalezení bounding boxů poté dosahuje zhruba 25 %. Je zde tedy rozhodně místo ke zlepšení, pravděpodobně vybrání sofistikovanější metody.

Reference

- [1] Wikipedia. Error level analysis — Wikipedia, the free encyclopedia. <https://bit.ly/2Y5gwBs>, 2019. [Online; accessed 02-May-2019].
- [2] May Yeung. Using tensorflow and support vector machine to create an image classifications engine. <https://bit.ly/2GcFtDG>, October 2016.
- [3] Peng Zhou, Xintong Han, Vlad I. Morariu, and Larry S. Davis. Learning rich features for image manipulation detection. *CoRR*, abs/1805.04953, 2018.